

(RFC): DSpro – Agentic Tri-Modal Spatio-Temporal Video RAG System

System: DSpro Agentic Spatio-Temporal RAG

Author: Ramzi AL-ashmali

Date: June 17, 2026

1. الملخص التنفيذي

نظام DSpro هو نظام ذكاء اصطناعي للوكلاء (Agentic) متعدد الوسائط، صُمم لاستيعاب ملفات الفيديو الخام (mp4/.mkv) بشكل مستقل وفهرستها للاسترجاع الدلالي العميق.

على عكس أنظمة التوليد المعزز بالاسترجاع (RAG) التقليدية القائمة على النصوص، يحقق DSpro فهماً مشتركاً (Joint Understanding) عبر ثلاثة أبعاد – تمت نمذجتها رياضياً كالتالي:

$$V = f(\text{Visual} + \text{Audio} + \text{Time})$$

. من خلال التعامل مع الفيديو كقاعدة بيانات متعددة الأبعاد، يتيح النظام للمستخدمين إرسال استعلامات معقدة ومتعددة اللغات (مثل العربية/الإنجليزية) واسترجاع الطوابع الزمنية الدقيقة لبداية ونهاية أحداث معينة. يتم تحقيق ذلك عبر بنية الدمج المتأخر (Late-Fusion)، والبحث الهجين في المتجهات (كثيف/متناثر)، وطبقة توجيه وكيالية تعتمد على النماذج اللغوية الكبيرة (Agentic LLM Routing Layer)، والتي تم تصميمها جميعاً للعمل بصرامة ضمن قيود أجهزة الحوسبة الطرفية (Edge-Hardware).

2. قيود الأجهزة وهيكلية النشر

القيد المعماري الأساسي هو بيئة النشر المستهدفة: جهاز محلي مزود بوحدة معالجة رسومات (GPU) من نوع NVIDIA RTX 2050 مع سقف صارم لذاكرة الفيديو (VRAM) يبلغ 4 جيجابايت. فرض هذا استخدام خط أنابيب مجزأ وعالي التحسين بدلاً من النماذج متعددة الوسائط الشاملة.

- هيكلية النشر: خدمات مصغرة معبأة في حاويات (Dockerized Microservices): تم تعبئة النظام بالكامل في حاويات باستخدام Docker Compose لضمان قابلية إعادة إنتاج البيئة (على أنظمة WSL 2 و Linux الأصلية).
- اختيار الصورة الأساسية (Base Image): تم رفض الصورة القياسية python:3.11-slim. لدعم أدوات بناء ++C وتبعيات مستوى نظام التشغيل التي تتطلبها مكتبات PyTorch و WhisperX، يستخدم النظام صورة وقت التشغيل الرسمية nvidia/cuda كصورة أساسية.
- قاعدة بيانات متجهات مخصصة: تعمل قاعدة بيانات Qdrant كحاوية مستقلة ومخصصة (qdrant/qdrant) مع وحدات تخزين دائمة. يعزل هذا ذاكرة قاعدة البيانات عن ذاكرة تطبيق Python، مما يلغي التطبيقات السابقة القائمة على الملفات المحلية.
- التمرير المباشر لوحدة معالجة الرسومات (GPU Pass-through): تمت تهيئته داخل ملف docker-compose.yml عبر توجيهه deploy.resources.reservations.devices، مما يمنح الواجهة الخلفية (FastAPI) وصولاً مباشراً وسريعاً (Low-latency) إلى بيئة CUDA.

3. بنية النظام وتدفق البيانات

يستخدم DSpro بنية الدمج المتأخر (Late-Fusion). إن معالجة الصوت والإطارات المرئية والنصوص في وقت واحد (الدمج المبكر) يتجاوز حد الـ 4 جيجابايت من VRAM. بدلاً من ذلك، تتم معالجة الوسائط بشكل مستقل بواسطة نماذج متخصصة وتدمج في مرحلة الاسترجاع النهائية باستخدام دمج الرتب المتبادل (RRF).

3.1 طبقة توجيه الوكيل المعتمدة على LLM (واجهة برمجة تطبيقات Gemini)

قبل عملية حساب المتجهات، تمر الاستعلامات عبر طبقة توجيه ذكية تعتمد على Gemini وتكون مسؤولة عن:

- التطبيع عبر اللغات (Cross-Lingual Normalization): ترجمة الاستعلامات العربية المعقدة إلى متجهات بحث إنجليزية محسنة.
- إزالة الحشو (Fluff Stripping): إزالة الكلمات الحوارية الزائدة لعزل القصد الدلالي الأساسي.
- توليد الحمولة (Payload Generation): هيكلة استعلام Qdrant محسن مع محاذاة تامة للمعلومات الدلالية الكثيفة ومعلومات BM25 المتناثرة.

3.2 صرامة واجهة برمجة تطبيقات البحث (FastAPI)

تحسب نقطة النهاية search/ محلياً ثلاثة مقاييس صارمة:

- start_timestamp (عائم - float)
- end_timestamp (عائم - float)
- hybrid_rrf_score (عائم - float): درجة تطابق تعكس مستوى الثقة وتجمع بين قوى الصوت والصورة والنص.

ملاحظة: يتم إلحاق البيانات الوصفية لواجهة المستخدم مثل video_id ومسارات الصور المصغرة باستجابة JSON دون تلوين المنطق الرياضي الأساسي للواجهة الخلفية.

4. محرك الاستيعاب (بروتوكول ترحيل VRAM)

لمنع انهيارات نفاد الذاكرة (OOM) في وحدات CUDA، يستخدم خط الأنابيب بروتوكول ترحيل متسلسل لـ VRAM مكون من 4 مراحل. يتم تحميل النماذج ديناميكياً في الذاكرة، وتنفيذها، ثم مسحها صراحةً عبر الأمر torch.cuda.empty_cache() قبل بدء المرحلة التالية.

- المرحلة 1: النسخ الصوتي والمحاذاة (WhisperX): يستخرج الصوت، وينسخ الكلام، ويحاذي الكلمات مع طابع زمني دقيقة.
- المرحلة 2: اكتشاف حدود المشهد (PySceneDetect): يقسم الفيديو بناءً على التقطيعات المرئية. ينفذ آلية تقطيع جزئي احتياطية مدتها 10 ثوانٍ للمشاهد الثابتة (مثل شرائح العرض التقديمي الطويلة).
- المرحلة 3: استخراج النص المرئي (EasyOCR): يفحص الإطارات الممثلة للمشاهد بحثاً عن نصوص تظهر على الشاشة (مثل: صيغ الأكواد البرمجية، وتسميات واجهة المستخدم).
- المرحلة 4: التحويل إلى متجهات (Vectorization):
- النمط الكثيف (Dense): يقوم نموذج OpenCLIP (ViT-B-32) بتضمين الإطارات المرئية في متجهات كثيفة بأبعاد 512.
- النمط المتناثر (Sparse): يقوم نموذج BM25 (عبر FastEmbed) بتحويل بيانات الصوت و OCR المدمجة إلى متجهات. يعمل بالكامل على وحدة المعالجة المركزية (CPU)، مما يوفر مطابقة دقيقة للكلمات الرئيسية دون استهلاك ذاكرة GPU.

5. قاعدة بيانات المتجهات ومحرك الاسترجاع

تدير قاعدة بيانات Qdrant مخططاً هجيناً متعدد الطبقات عبر المتجهات المسماة (Named Vectors)، مما يتيح الاستعلامات المتزامنة عبر أنواع متباينة من البيانات.

5.1 تصميم المخطط (Schema Design)

- clip_visual: متجهات كثيفة بأبعاد 512، مسافة جيب التمام (للمظهر الدلالي).
- text_dense: متجهات كثيفة بأبعاد 512، مسافة جيب التمام (للمعنى الدلالي للكلام/النص).
- text_sparse: متجهات متناثرة BM25 (للتكرار المعجمي الدقيق للمصطلحات التقنية).

5.2 دمج الرتب المتبادل ثلاثي الوسائط (RRF)

ينفذ النظام ثلاثة عمليات بحث موازية في المتجهات ويدمج رتبها باستخدام RRF. يكافئ هذا المقاطع التي تسجل درجات عالية عبر وسائط متعددة في وقت واحد.

- التنفيذ: 3 قوائم جلب مسبق منفصلة ($k=60$). أقصى درجة ممكنة للمركز الأول عبر جميع الوسائط الثلاثة هي $3 \times 0.0492 \approx 0.1476$.
- الحماية من الهلوسة (Hallucination Guard): يتم فرض حد أدنى صارم قدره 0.04 على مستوى واجهة برمجة التطبيقات. يتم رفض النتائج التي تسجل أقل من هذا الحد باعتبارها خارج التوزيع (OOD)، مما يمنع مغالطة "أقرب جار" (Nearest Neighbor Fallacy).

6. مقاييس الأداء وميزانية زمن انتقال الاستعلام

استناداً إلى سجلات الخادم الحية الملتقطة على خادم التطوير `uvicorn main:app` (الذي يعمل بإصدار PyTorch 2.11.0+cu128)، يحافظ النظام على سرعة استرجاع محسنة للغاية. بمجرد فهرسة الفيديو بالكامل عبر جميع الوسائط الثلاثة في Qdrant، يصبح الاستعلام من قاعدة البيانات سريعاً بشكل استثنائي.

6.1 تفصيل زمن انتقال مرحلة الاستعلام

الوصف	متوسط زمن الانتقال	مرحلة الاستعلام
رحلة شبكة ذهاباً وإياباً إلى واجهة برمجة تطبيقات Gemini للترجمة والتنسيق	~400ms – 800ms	1. تحسين الاستعلام عبر LLM
تشغيل النص محلياً عبر OpenCLIP (تنفيذ محلي على GPU).	~20ms	2. تحويل الاستعلام إلى متجهات
بحث متوازٍ ودمج رياضي فوري عبر خوارزمية RRF.	~10ms	3. بحث Qdrant الهجين باستخدام RRF
من نقرة واجهة المستخدم إلى ظهور بطاقة النتائج المكتملة وتحديد موقع الفيديو.	أقل من 1 ثانية	إجمالي وقت الاستجابة

6.2 مقاييس صحة النظام

تؤكد الاختبارات المكثفة الاستقرار التشغيلي للنظام على جميع الأصعدة:

المقياس	الهدف	الأداء الفعلي	الحالة
سقف الـ VRAM	> 4.0 جيجابايت	صفر انهيارات (OOM) عبر الاختبارات الصارمة.	اجتاز ✓
استقرار واجهة برمجة التطبيقات	100% وقت تشغيل	جميع نقاط النهاية الثمانية تُرجع OK 200 باستمرار.	اجتاز ✓
لتعرف البصري (OCR) عبر اللغات	عربي/إنجليزي	يجد النظام الأكواد الإنجليزية بدقة عبر مطالبات باللغة العربية.	اجتاز ✓
معدل الهلوسة	0% إيجابيات خاطئة	يقوم حد الحماية (0.04) بتصفية استعلامات OOD باستمرار.	اجتاز ✓

7. التحديات الهندسية والحلول

- 7.1 تجاوز جحيم تبعيات ++C: فشلت عمليات بناء حاويات Docker الأولية بسبب فقدان ملفات ++C الأساسية (Headers) لمكتبات الصوت (CTranslate2 و TorchCodec). الحل: تم الترحيل إلى الصورة الأساسية لـ NVIDIA CUDA وحقن أمر apt-get install -y ffmpeg صراحةً في ملف Dockerfile، مما ضمن توفر الملفات الثنائية (Binaries) المشتركة بالكامل على مستوى نظام التشغيل لمكتبة PyTorch.
- 7.2 هلوسات توجيه النماذج اللغوية (LLM): أدت الاستعلامات العربية المعقدة أحياناً إلى توليد حمولات بحث ضعيفة، مما أدى إلى استرجاع مقاطع فيديو غير ذات صلة. الحل: تم تنفيذ موجه نظام SYSTEM_PROMPT صارم كثابت عام (Global Constant)، مما قيّد نموذج LLM بشكل صارم بتعليمات الترجمة واستهداف المتجهات فقط. وبالاقتراح مع حد الحماية 0.04 الخاص بـ RRF، تم القضاء على الإيجابيات الخاطئة بالكامل.

8. الخلاصة والعمل المستقبلي

الحكم النهائي: جاهز للإنتاج (PRODUCTION-READY). حقق نظام DSpro بنجاح مهمته الأساسية: وقت استجابة إجمالي يقل عن ثانية واحدة لاسترجاع مقاطع الفيديو المعقدة ومتعددة اللغات والمكانية-الزمانية، وذلك في ظل قيود صارمة لأجهزة طرفية لا تتجاوز 4 جيجابايت من VRAM.

المخرجات المنجزة:

- ✓ محرك استيعاب مستقل ومتعدد الوسائط (صوت، صورة، نص).
- ✓ واجهة برمجة تطبيقات بحث (Search API) عالية السرعة تُرجع طوابع زمنية دقيقة وبيانات وصفية مدمجة.
- ✓ بنية GPU قابلة للنقل بالكامل عبر خدمات Docker Compose.

خط أنابيب التحسين المستقبلي:

- تكميم المتجهات (Vector Quantization): تنفيذ تكميم INT8 أو fp16 لمتجهات OpenCLIP لتقليل العبء على VRAM ومساحة القرص بنسبة تصل إلى 50% دون فقدان كبير في دقة جيب التمام (Cosine Accuracy).
- فهرسة البحث عن النص الكامل (Full-Text Search Indexing): تقديم فهرس حمولة (Payload Index) مخصص في Qdrant للبيانات الوصفية للنصوص (Transcripts)، ليكون بمثابة خيار احتياطي دقيق للبحث النصي التقليدي عن السلاسل الفرعية.